

$X$  v.a.  $f(x|\theta)$ ,  $\theta \in \Theta \rightarrow$  ESPAÇO PARAMÉTRICO

↳ PARÂMETRO CONHECIDO FIXO

Estatística -  $T(\underline{x}) = T(x_1, \dots, x_n)$

• MéDIA  $\bar{X} = \frac{\sum x_i}{n}$

• Mínimo  $X_{(1)} = \min\{x_1, \dots, x_n\}$

• MÁximo  $X_{(n)} = \max\{x_1, \dots, x_n\}$

• Variância  $S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$

} ESTIMADOR de  $\theta$  }  $\hat{\theta}$

Propriedade Suficiência:

→ ESTATÍSTICA SUFICIENTE

$$f(x|\theta) = f(x_1, \dots, x_n|\theta) = g(\tilde{S}(x), \theta) h(x)$$

$X \sim \text{Bernoulli}(\theta)$

↳ UM PARÂMETRO

$X \sim \text{Normal}(\mu, \sigma^2)$

↳ DOIS PARÂMETROS

$$\tilde{\theta} = (\mu, \sigma^2)$$

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma^2} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot I_{(-\infty, \infty)}(x)$$

FAMÍLIA EXPONENCIAL

$$f(x|\theta) = a(\theta) \cdot b(x) \cdot e^{c(\theta) \cdot d(x)}$$

## Slide 42

$X_1, \dots, X_n$  a.a  $N(\mu, \sigma^2)$   $\mu, \sigma^2$  desconhecidos

$$X \sim N(\mu, \sigma^2)$$

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\begin{aligned} f(\underline{x} | \theta) &= \prod_{i=1}^n f(x_i | \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = \\ &= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{\sum(x_i-\mu)^2}{2\sigma^2}} = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{\sum x_i^2 - n\mu \sum x_i + n\mu^2}{2\sigma^2}} = \\ &= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{\sum x_i^2 - 2n\mu \bar{x} + n\mu^2}{2\sigma^2}} \end{aligned}$$

Considerando dois pontos amostrais  $\underline{x}$  e  $\underline{y}$ , temos:

$$\frac{f(\underline{x} | \theta)}{f(\underline{y} | \theta)} = \frac{\left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{\sum x_i^2 - 2n\mu \bar{x} + n\mu^2}{2\sigma^2} \right\}}{\left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{\sum y_i^2 - 2n\mu \bar{y} + n\mu^2}{2\sigma^2} \right\}}$$

$$\frac{f(\underline{x} | \theta)}{f(\underline{y} | \theta)} = \exp \left\{ -\frac{1}{2\sigma^2} \cdot \left( \sum x_i^2 - \sum y_i^2 - 2n\mu [\bar{x} - \bar{y}] \right) \right\}$$

SABEMOS que:

$$S_x^2 = \frac{\sum x_i^2 - n\bar{x}^2}{n-1} \Rightarrow \sum x_i^2 = n\bar{x}^2 + (n-1)S_x^2$$

Substituindo na Equação

$$\frac{f(\underline{x} | \theta)}{f(\underline{y} | \theta)} = \exp \left\{ -\frac{1}{2\sigma^2} \left[ n(\bar{x}^2 - \bar{y}^2) + (n-1)(S_x^2 - S_y^2) - 2n\bar{y}(\bar{x} - \bar{y}) \right] \right\}$$

Sendo  $T(\underline{x}) = (\bar{x}, S_x^2)$ , a equação acima será constante em função de  $(\mu, \sigma^2)$  quando  $\bar{x} = \bar{y}$  e  $S_x^2 = S_y^2$ . Dessa forma,  $\bar{X} = \frac{\sum x_i}{n}$  e  $S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$

São estatísticas suficientes mínimas para  $\mu$  e  $\sigma^2$

### Slide 43

Exemplo:  $X_1, \dots, X_n$  a.a. Bernulli( $p$ )

$T_1 = \sum_{i=1}^n X_i$  é completa?

SABEMOS que  $T_L \sim \text{Bin}(n, p)$

$$P(T_1 = k | p) = \binom{n}{k} p^k (1-p)^{n-k} \underset{\{0, 1, \dots, n\}}{\pm}_{(k)}$$

$$E(g(T_1)) = \sum_{k=0}^n g(k) \cdot \binom{n}{k} p^k (1-p)^{n-k} =$$

$$= \sum_{t=0}^n g(t) \binom{n}{t} \underbrace{\left(\frac{p}{1-p}\right)^t}_{>0} \cdot (1-p)^n, \quad p \in (0,1)$$

$$\binom{n}{t} = \frac{n!}{t!(n-t)!}$$

A equação acima será nula somente se  $g(t) = 0$  para todo  $t$ . Logo,  $T_1(X) = \sum_{i=1}^n X_i$  é uma estatística completa.

$T_2 = X_2 - X_1$  é completa?

Considere  $\boxed{g(t) = t}$  então

$$E(g(T_2)) = E(X_2 - X_1) = E(X_2) - E(X_1) = p - p = 0$$

Assim, como  $E(g(T_2)) = 0$  para  $g(t) = t$ , então  $T_2 = X_2 - X_1$  NÃO é uma estatística completa.

Família Exponencial  $X \sim f(x|\theta)$

$$f(x|\theta) = a(\theta) b(x) e^{c(\theta) \cdot d(x)}$$

$X_1, \dots, X_n$  a.a.

$T(X) = \sum_{i=1}^n d(X_i)$  é uma estatística suficiente minimal completa

## Slide 44

Exemplo:  $X_1, \dots, X_n$  a.a. Poisson( $\lambda$ )

$X \sim P(\lambda)$ , então

$$f(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!} \cdot I_{\{0,1,\dots\}}(x) =$$

$$= \underbrace{e^{-\lambda}}_{a(\lambda)} \cdot \underbrace{\frac{1}{x!} \cdot I_{\{0,1,\dots\}}(x)}_{b(x)} \cdot e^{x \ln \lambda \rightarrow c(\lambda)}$$

Como a distribuição Poisson e  $\lambda \in \Theta = (0, \infty)$  pertence à família exponencial, então

$$T(\underline{x}) = \sum_{i=1}^n d(x_i) = \sum_{i=1}^n x_i \text{ é uma estatística}$$

Suficiente minimal completa

## Slide 46

Exemplo:  $X_1, \dots, X_n$  a.a.  $N(\mu, \sigma^2)$

$X \sim N(\mu, \sigma^2) \quad \Theta = (\mu, \sigma^2)$

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \cdot I_{(-\infty, \infty)}(x)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left\{-\frac{\mu^2}{2\sigma^2}\right\} \cdot I_{(-\infty, \infty)}(x) \cdot \exp\left\{-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x\right\}$$

Temos que  $c_1(\theta) = \frac{-1}{2}\sigma^2 \in (-\infty, 0)$  e

$c_2(\theta) = \frac{1}{\sigma^2} \in (-\infty, \infty)$ , então

$$T(\underline{x}) = (\sum d_1(\underline{x}), \sum d_2(\underline{x})) = (\sum x_i^2, \sum x_i)$$

São estatísticas conjuntamente suficientes e completa.

## Método de Momentos

Momentos populacionais

$$\mu'_r = E(X^r)$$

$\bar{X}$

Momentos amostrais

$$\hat{\mu}'_r = \frac{\sum x_i^r}{n}$$

## Slide 48

Exemplo:  $X_1, X_2, \dots, X_n$  iid.  $X \sim \text{Exp}(\theta)$

$$r=1 \Rightarrow \mu'_1 = E(X) = \frac{1}{\theta} \quad (1^{\circ} \text{ momento populacional})$$

$$\hat{\mu}'_1 = \frac{\sum x_i}{n} = \bar{X} \quad (1^{\circ} \text{ momento amostral})$$

Pelo método de momentos temos que

$$\frac{1}{\hat{\theta}} = \bar{X} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

é o estimador de  $\theta$  pelo método de momentos

b)  $X_1, X_2, \dots, X_n$  a. a.  $N(\mu, \sigma^2)$

Momentos populacionais      Momentos amostrais

$$\begin{cases} M_1' = E(X) = \mu \\ M_2' = E(X^2) = \sigma^2 + \mu^2 \end{cases}$$

$$\begin{cases} M_1 = \frac{\sum X_i}{n} = \bar{X} \\ M_2 = \frac{\sum X_i^2}{n} \end{cases}$$

$$\text{Var}(X) = \sigma^2 = E(X^2) - (E(X))^2 = E(X^2) - \mu^2$$

Comparando os momentos populacionais e amostrais, temos:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 + \hat{\mu}^2 = \frac{\sum X_i^2}{n}$$

$$\hat{\sigma}^2 = \frac{\sum X_i^2}{n} - \bar{X}^2 = \frac{\sum X_i^2 - n\bar{X}^2}{n} = \frac{\sum (X_i - \bar{X})^2}{n}$$

$$\sum (X_i - \bar{X})^2 = \sum X_i^2 - 2\bar{X} \cdot \sum X_i + n\bar{X}^2$$

$$= \sum X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum X_i^2 - n\bar{X}^2$$

luego,  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{\sum (X_i - \bar{X})^2}{n}$  são os

estimadores de  $\mu$  e  $\sigma^2$  pelo método de momentos

## Slide 50

X: Face CARA no Lançamento de uma moeda

$\theta$ : probabilidade de sair a FACE CARA

$X_1$  e  $X_2$  a.a. X

$X \sim \text{Bernoulli}(\theta)$

$$P(X=x|\theta) = \theta^x (1-\theta)^{1-x} \underset{(0,1)}{I(x)}$$

A FUNÇÃO de Verossimilhança é DADA por

$$L(\theta | \underline{x}) = f(x_1, x_2 | \theta) = \prod_{i=1}^2 f(x_i | \theta) =$$

$$= \theta^{x_1} (1-\theta)^{1-x_1} \cdot \theta^{x_2} (1-\theta)^{1-x_2} =$$

$$= \theta^{x_1+x_2} (1-\theta)^{2-x_1-x_2}$$

VAMOS SIMULAR AS POSSIBILIDADES

$$\circ (x_1, x_2) = (0, 0)$$

$$\circ (x_1, x_2) = (1, 1)$$

$$L(\theta | \underline{x}) = (1-\theta)^2$$

$$L(\theta | \underline{x}) = \theta^2$$
  
 $\theta \in (0,1)$

$$\circ (x_1, x_2) = (0, 1)$$

$$L(\theta | \underline{x}) = \theta(1-\theta)$$