

## Slide 55

①  $X_1, \dots, X_n$  a.a. Bernoulli( $\theta$ ) , Emv de  $\theta$ ?

$X \sim \text{Bernoulli}(\theta)$ , então  $f(x|\theta) = \theta^x (1-\theta)^{1-x} \cdot I_{(0,1)}(x)$

SABEMOS que a Dist. de Bernoulli pertence à Família Exponencial, então as condições de regularidade estão satisfeitas.

A Função de verossimilhança de  $\theta$  é dada por

$$\begin{aligned} L(\theta | \underline{x}) &= \prod_{i=1}^n f(x_i | \theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} \cdot I_{(0,1)}(x_i) = \\ &= \theta^{\sum x_i} (1-\theta)^{n-\sum x_i} \prod_{i=1}^n I_{(0,1)}(x_i) \end{aligned}$$

Calculamos o logaritmo natural da função de verossimilhança.

$$\ln L(\theta | \underline{x}) = \sum x_i \cdot \ln \theta + (n - \sum x_i) \cdot \ln (1-\theta) + \ln \left[ \prod_{i=1}^n I_{(0,1)}(x_i) \right]$$

$$\frac{\partial \ln L(\theta | \underline{x})}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{(n - \sum x_i)}{1-\theta}$$

$$\frac{\sum x_i}{\hat{\theta}} - \frac{(n - \sum x_i)}{1-\hat{\theta}} = 0 \Rightarrow \frac{(1-\hat{\theta})\sum x_i - \hat{\theta}(n - \sum x_i)}{\hat{\theta}(1-\hat{\theta})} = 0$$

$$\frac{\sum x_i - \hat{\theta}\sum x_i - \hat{\theta} \cdot n + \hat{\theta} \cdot \sum x_i}{\hat{\theta}(1-\hat{\theta})} = 0 \Rightarrow \frac{\sum x_i - \hat{\theta}n}{\hat{\theta}(1-\hat{\theta})} = 0$$

$$\sum x_i - \hat{\theta}n = 0 \Rightarrow \hat{\theta} = \frac{\sum x_i}{n} = \bar{x}$$

Verificando se  $\hat{\theta} = \bar{x}$  é ponto de máximos

$$\frac{\partial \ln L(\theta | x)}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{(n - \sum x_i)}{1-\theta}$$

$$\frac{\partial^2 \ln L(\theta | x)}{\partial \theta^2} = -\frac{\sum x_i}{\theta^2} - \frac{(n - \sum x_i)}{(1-\theta)^2}$$

$$\left. \frac{\partial^2 \ln L(\theta | x)}{\partial \theta^2} \right|_{\theta=\hat{\theta}} = -\frac{\sum x_i}{\frac{(\sum x_i)^2}{n^2}} - \frac{(n - \sum x_i)}{\left(1 - \frac{\sum x_i}{n}\right)^2} =$$

$$= -\frac{n^2 \sum x_i}{(\sum x_i)^2} - \frac{(n - \sum x_i)}{1 - 2\frac{\sum x_i}{n} + \frac{\sum x_i^2}{n^2}} = -\frac{n^2}{\sum x_i} - \frac{(n - \sum x_i)}{\frac{n^2 - n^2 \sum x_i + \sum x_i^2}{n^2}} =$$

$$= -\frac{n^2}{\sum x_i} - \frac{n^2(n - \sum x_i)}{(n - \sum x_i)^2} = -\frac{n^2}{\sum x_i} - \frac{n^2}{n - \sum x_i} =$$

$$= -n^2 \left( \frac{1}{\sum x_i} + \frac{1}{n - \sum x_i} \right) > 0$$

Logo  $\hat{\theta} = \bar{x}$  é ponto de máximos.

<0

②  $X_1, \dots, X_n$  a.o.  $N(\mu, \sigma^2)$   $\mu$  e  $\sigma^2$  desconhecidos

$X \sim N(\mu, \sigma^2)$ , então

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\} \cdot I_{(-\infty, \infty)}$$

SABEMOS que a Distribuição Normal com  $\mu$  e  $\sigma^2$  desconhecidos pertence à família exponencial, logo, as condições regularizadas estão satisfeitas.

A Função de Verossimilhança de  $\Theta = (\mu, \sigma^2)$

$$L(\underline{\theta} | \underline{x}) = \prod_{i=1}^n f(x_i | \underline{\theta}) =$$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \cdot \prod_{i=1}^n I_{(-\infty, \infty)}(x_i) =$$

$$= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \cdot \exp \left\{ -\frac{\sum (x_i - \mu)^2}{2\sigma^2} \right\} \cdot \prod_{i=1}^n I_{(-\infty, \infty)}(x_i)$$

O Logaritmo da Função de Verossimilhança é dado por:

$$\ln L(\underline{\theta} | \underline{x}) = \ln(2\pi\sigma^2)^{-\frac{n}{2}} - \frac{\sum (x_i - \mu)^2}{2\sigma^2} + \ln \prod_{i=1}^n I(x_i)$$

$$\frac{\partial \ln L(\underline{\theta} | \underline{x})}{\partial \mu} = -2 \frac{\sum (x_i - \mu) \cdot (-1)}{2\sigma^2} = \frac{\sum (x_i - \mu)}{\sigma^2} = \frac{\sum x_i - n\mu}{\sigma^2}$$

$$\frac{\partial^2 \ln L(\underline{\theta} | \underline{x})}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum (x_i - \mu)^2}{2(\sigma^2)^2}$$

Igualando a zero temos:

$$\frac{\sum x_i - n\hat{\mu}}{\hat{\sigma}^2} = 0 \Rightarrow \sum x_i - n\hat{\mu} = 0 \Rightarrow \hat{\mu} = \frac{\sum x_i}{n} = \bar{x}$$

$$\frac{-n}{2\hat{\sigma}^2} + \frac{\sum (x_i - \hat{x})^2}{2(\hat{\sigma}^2)^2} = 0 \Rightarrow \frac{n\hat{\sigma}^2 - \sum (x_i - \bar{x})^2}{2(\hat{\sigma}^2)^2} = 0$$

$$n\hat{\sigma}^2 = \sum (x_i - \bar{x})^2 \Rightarrow \hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n}$$

Após AVALIAR A SEGUNDA DERIVADA, podemos concluir que  
 $\bar{x}$  e  $\hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n}$  SÃO OS EMV  $\theta = (\bar{x}, \hat{\sigma}^2)$ .  
 → calcular depois

③  $X_1, \dots, X_n$  a.a.  $U(0, \theta)$ ,  $\theta > 0$  EMV de  $\theta$ .

$$X \sim U(0, \theta), \text{ então } f(x|\theta) = \frac{1}{\theta} \cdot I(x)$$

Como a distribuição Uniforme NÃO pertence à Família Exponencial, então NÃO SATISFAZ às condições de regularidade.


A FUNÇÃO DE VEROSIMILANÇA DE  $\theta$  é

$$L(\theta | \underline{x}) = \prod_{i=1}^n \frac{1}{\theta} \cdot I(x_i) = \frac{1}{\theta^n} \cdot \prod_{i=1}^n I(x_i)$$

$$\prod_{i=1}^n I(x_i) = \begin{cases} 1, & \begin{array}{l} 0 < x_1 < \theta \\ 0 < x_2 < \theta \\ \vdots \\ 0 < x_n < \theta \end{array} \Rightarrow X_{(n)} = y_n = \max\{x_1, \dots, x_n\}, \\ 0, & \text{c.c.} \end{cases}$$

$$L(\theta | \underline{x}) = \frac{1}{\theta^n} \cdot I(\theta) \quad (y_n, \infty)$$

Pelo gráfico  $\hat{\theta} = y_n$  e o EMV de  $\theta$ .



④  $X_1, \dots, X_n$  a.a.  $U(\theta-1, \theta+1)$  Emv de  $\theta$ .


$$X \sim U(\theta-1, \theta+1), \text{ então } f(x|\theta) = \frac{1}{2} \cdot I_{(\theta-1, \theta+1)}(x)$$

Como a distribuição Uniforme NÃO pertence à Família Exponencial, então NÃO SATISFAZ às condições de regularidade.

A FUNÇÃO DE VEROSIMILHANÇA DE  $\theta$  é

$$\begin{aligned} L(\theta | \underline{x}) &= \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{1}{2} \cdot I_{(\theta-1, \theta+1)}(x_i) = \frac{1}{2^n} \prod_{i=1}^n I_{(\theta-1, \theta+1)}(x_i) = \\ &= \frac{1}{2^n} \prod_{i=1}^n I_{(\theta-1, \theta+1)}(x_i) = \begin{cases} 1, & \theta-1 < x_1 < \theta+1 \\ & \theta-1 < x_2 < \theta+1 \\ & \vdots \\ & \theta-1 < x_n < \theta+1 \\ 0, & \text{e.c.} \end{cases} \quad \begin{array}{l} x_{(n)} < \theta+1 \therefore \theta > x_{(n)}-1 \\ \theta-1 < x_1 \therefore \theta < x_{(1)}+1 \\ \downarrow \\ x_{(n)}-1 < \theta < x_{(1)}+1 \end{array} \end{aligned}$$

$$L(\theta | \underline{x}) = \frac{1}{2^n} I_{(x_{(n)}-1, x_{(1)}+1)}(\theta) \quad \begin{array}{l} \text{em que } x_{(1)} = \min\{x_1, \dots, x_n\} \\ \text{e } x_{(n)} = \max\{x_1, \dots, x_n\} \end{array}$$



O Emv de  $\theta$  pode ser escrito como

$$\hat{\theta} = \alpha(x_{(n)} - 1) + (1-\alpha)(x_{(1)} + 1) \text{ com } \alpha \in (0,1)$$

$$\text{e } x_{(1)} = \min\{x_1, \dots, x_n\} \text{ e } x_{(n)} = \max\{x_1, \dots, x_n\}.$$

## Slide 56

### Demonstração do Teorema

$X_1, \dots, X_n$  a.a.  $X$  com  $f(x|\theta)$  e  $T = T(X_1, \dots, X_n)$  uma estatística suficiente.

A função de verossimilhança é  
 $L(\theta | \underline{x}) = f(\underline{x} | \theta) = g(T(\underline{x})) ; \theta) h(\underline{x})$ , pela fatoração de Neymann.

Assim,  $g(T(\underline{x}), \theta)$  depende da amostra somente através de  $T$  e maximizar a função de verossimilhança em relação a  $\theta$  equivale a maximizar  $g(T(\underline{x}), \theta)$ . Assim o Emv de  $\theta$  será função de  $T$ .

## Slide 57

①  $X_1, X_2, \dots, X_n$  a.a. Bernoulli( $\theta$ ) Emv de  $g(\theta) = \theta(1-\theta)$   
 $g(\theta) = \theta(1-\theta) = \text{Var}(X)$

SABEMOS que o Emv de  $\theta = \bar{X}$  (Slide 55), então pela propriedade da invariância dos Emv temos que  $\widehat{g(\theta)} = g(\widehat{\theta}) = \widehat{\theta}(1-\widehat{\theta}) = \bar{X}(1-\bar{X})$  é o Emv de  $g(\theta)$

②  $X_1, \dots, X_n$  a.a.  $N(\mu, 1)$  Emv  $g(\mu) = P(X \leq 0)$

$X \sim N(\mu, 1)$ , então

$$f(x|\mu) = \frac{1}{\sqrt{2\pi}} \cdot \exp \left\{ -\frac{(x-\mu)^2}{2} \right\} \cdot I_{(-\infty, \infty)}(x)$$

Como pertence à família exponencial, as condições de regularidade estão satisfeitas.

A FUNÇÃO DE VEROSIMILHANÇA PARA  $\mu$  é

$$L(\mu | \underline{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \cdot \exp \left\{ -\frac{(x_i - \mu)^2}{2} \right\} \cdot I_{(-\infty, \infty)}(x_i) = \\ = \left( \frac{1}{\sqrt{2\pi}} \right)^n \cdot \exp \left\{ -\sum \frac{(x_i - \mu)^2}{2} \right\} \cdot \prod_{i=1}^n I_{(-\infty, \infty)}(x_i)$$

O logaritmo da função de verosimilhança é

$$\ln L(\mu | \underline{x}) = n \ln(\sqrt{2\pi}) - \sum \frac{(x_i - \mu)^2}{2} + \ln \prod_{i=1}^n I_{(-\infty, \infty)}(x_i)$$

$$\frac{\partial \ln L(\mu | \underline{x})}{\partial \mu} = \sum (x_i - \hat{\mu}) = 0$$

$$\sum x_i - n\hat{\mu} = 0 \Rightarrow \hat{\mu} = \frac{\sum x_i}{n} = \bar{x}$$

Após verificar a segunda derivada (FAZER) temos que  $\hat{\mu} = \frac{\sum x_i}{n} = \bar{x}$  é o EmV de  $\mu$ .

Pela propriedade de INVARIÂNCIA DOS EMV, temos que

$$g(\mu) = P(X \leq 0) = P\left(\frac{X - \mu}{1} \leq -\frac{\mu}{1}\right) = P(Z \leq -\mu)$$

em que  $Z$  tem distribuição normal com média zero e variância um.

$E \hat{g}(u) = g(\hat{y}) = P(Z \leq -u)$  é o EmV de  
 $g(u) = P(X \leq u)$