

# Filtros Bayesianos

## Princípios de Inferência Estatística

Maicon C. Germano

IBB UNESP

24 de maio de 2023

## 1 Introdução

- O que é inferência Bayesiana?
- Inferência Bayesiana vs. Clássica
- Distribuição a priori

## 2 Teorema de Bayes

- Breve revisão
- Exemplo 1

## 3 Intervalos de credibilidade

- Resumindo informação a posteriori
- Região de credibilidade
- Exemplo 2
- Como obter a posteriori a partir do exemplo 2?

## 4 Aplicação na radioterapia

## 5 Conclusão

# O que é inferência Bayesiana?

- A inferência Bayesiana é um método estatístico que leva em conta informações prévias sobre o que está sendo analisado.
- Ela combina essas informações com os novos dados que estão sendo analisados para chegar a uma conclusão mais precisa e confiável.
- O parâmetro populacional  $\theta$  é tratado como uma quantidade aleatória, o que leva a abordagens substancialmente diferentes à modelagem e inferência em comparação à inferência clássica.

# O que é inferência Bayesiana?

- A inferência Bayesiana é baseada em  $f(\theta | y)$  ao invés de se basear em  $f(y | \theta)$ , ou seja, na probabilidade do parâmetro condicional aos dados obtidos.
- Para utilizar a inferência Bayesiana, é necessário especificar uma distribuição a priori de probabilidades  $f(\theta)$  que representa as crenças sobre a distribuição de  $\theta$  antes de se considerar qualquer informação proveniente dos dados.
- A noção de distribuição a priori para o parâmetro  $\theta$  está no cerne do pensamento bayesiano.

# Inferência Bayesiana vs. Clássica

- Existem diferentes maneiras de analisar dados e chegar a conclusões estatísticas. Duas dessas maneiras são a inferência Bayesiana e a inferência clássica.
- A inferência Bayesiana é um método que permite que se leve em conta informações prévias sobre o que está sendo analisado, como experiências anteriores ou conhecimentos sobre o assunto. Ela combina essas informações com os novos dados que estão sendo analisados, para chegar a uma conclusão mais precisa e confiável.

# Inferência Bayesiana vs. Clássica

- Já a inferência clássica é uma maneira mais tradicional de analisar dados, sem levar em conta informações prévias. Nesse método, são usados estimadores de máxima verossimilhança, que buscam encontrar a estimativa mais provável dos parâmetros do modelo que está sendo analisado.
- A principal diferença entre esses dois métodos é que a inferência Bayesiana leva em conta informações prévias, enquanto a inferência clássica não o faz. Isso pode fazer com que a inferência Bayesiana seja mais precisa e confiável em algumas situações.

- Ao tentar estimar um parâmetro  $\theta$ , é comum ter algum conhecimento ou crença prévia sobre o valor de  $\theta$  antes de considerar os dados.
- A distribuição a priori representa a crença prévia sobre o valor de  $\theta$ , antes de observar os dados.
- A informação da distribuição a priori é combinada com a informação dos dados para obter a distribuição a posteriori, que reflete a crença atualizada sobre o valor de  $\theta$ .

- A distribuição a priori pode ser baseada em conhecimento prévio, experiências anteriores, especialistas ou modelos teóricos.
- A distribuição a priori pode influenciar as inferências feitas a partir dos dados, pois pode levar a diferentes distribuições a posteriori e conclusões diferentes.
- A escolha da distribuição a priori pode ser subjetiva e pode levar a diferentes inferências entre diferentes indivíduos ou grupos.



# Teorema de Bayes: revisão

Em sua forma básica, o Teorema de Bayes é simplesmente um resultado de probabilidade condicional:

## Teorema de Bayes

### Teorema (1)

Se  $A$  e  $B$  são dois eventos com  $P(A) > 0$  então:

$$P(B | A) = \frac{P(A|B)P(B)}{P(A)}$$

**Exemplo 1.** Um procedimento de testes de diagnóstico para HIV é aplicado a uma população de alto risco; acredita-se que 10% desta população é positiva para o HIV. O teste de diagnóstico é positivo para 90% das pessoas que de fato são HIV-positivas, e negativo para 85% das pessoas que não são HIV-positivas. Qual a probabilidade de resultados falso-positivo e falso-negativo?

**Notação:**

$A$ : a pessoa é HIV-positiva,  $B$ : o resultado do teste é positivo. Temos dados que  $P(A) = 0,1$ ,  $P(B | A) = 0,9$  e  $P(\bar{B} | \bar{A}) = 0,85$ . Então:

$$\begin{aligned} P(\text{falso positivo}) &= P(\bar{A} | B) = \frac{P(B | \bar{A})P(\bar{A})}{P(B)} \\ &= \frac{0,15 \times 0,9}{(0,15 \times 0,9) + (0,9 \times 0,1)} = 0,6 \end{aligned}$$

De forma similar,

$$P(\text{falso negativo}) = P(A | \bar{B})$$

$$= \frac{P(\bar{B} | A)P(A)}{P(\bar{B})}$$

$$= \frac{0,1 \times 0,1}{(0,1 \times 0,1) + (0,85 \times 0,9)} = 0,0129$$

## Intervalos de credibilidade

- A ideia do intervalo de credibilidade é criar um análogo ao intervalo de confiança da estatística frequentista.
- Estimativas pontuais não fornecem uma medida de precisão, portanto, é preferível informar um intervalo no resultado das análises.
- Na estatística frequentista, isso causa problemas, pois os parâmetros não são considerados aleatórios, tornando impossível dar um intervalo com a interpretação de que há uma certa probabilidade de o parâmetro estar dentro do intervalo.
- Em vez disso, os intervalos de confiança devem ser interpretados como se a amostragem fosse repetida inúmeras vezes, haveria uma probabilidade especificada de que o intervalo contivesse o parâmetro - ou seja, o intervalo é aleatório e não o parâmetro.

Na abordagem bayesiana, os parâmetros são tratados como aleatórios. Assim, uma região  $C_\alpha(y)$  é uma região de credibilidade  $100(1 - \alpha)\%$  para  $\theta$  se

$$\int_{C_\alpha(y)} f(\theta | y) d\theta = 1 - \alpha. \quad (1)$$

Ou seja, existe uma probabilidade de  $1 - \alpha$ , com base na distribuição posteriori, que  $\theta$  esteja contido em  $C_\alpha(y)$ .

- Uma dificuldade com o intervalo de credibilidade (que também ocorre com intervalos de confiança), é que eles não são unicamente definidos.
- Qualquer região com probabilidade  $1 - \alpha$  é um intervalo válido.
- Deseja-se um intervalo que contenha apenas os valores mais plausíveis do parâmetro, por isso é habitual impor uma restrição adicional, que a largura do intervalo seja tão pequena quanto possível.
- Isso equivale a um intervalo (ou região) da forma:  
$$C_\alpha(y) = \{\theta : f(\theta | y) \geq \gamma\}$$

Em que  $\gamma$  é escolhido para garantir que:

$$\int_{C_\alpha(y)} f(\theta | y) d\theta = 1 - \alpha$$

Tais regiões são chamadas de regiões com mais alta densidade posteriori (HPD). Esses intervalos são encontrados numericamente, embora existam valores tabulados para algumas distribuições posteriores univariadas. É importante lembrar que a escolha do valor de  $\alpha$  pode afetar a largura do intervalo, resultando em um "perde/ganha": um valor pequeno resulta em um intervalo largo, enquanto um valor grande resulta em um intervalo com baixa probabilidade de conter o parâmetro.

**Exemplo 2.** (Média normal.) Sejam  $Y_1, \dots, Y_n$  variáveis independentes de uma distribuição  $N(\theta, \sigma^2)$ , ( $\sigma^2$  conhecido) com uma priori para  $\theta$  da forma  $\theta \sim N(b, d^2)$ .

**Resolução:**

Com essas informações, obtém-se a posteriori:

$$\theta \mid y \sim N \left( \frac{\frac{b}{d^2} + \frac{n\bar{y}}{\sigma^2}}{\frac{1}{d^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{d^2} + \frac{n}{\sigma^2}} \right) \quad (2)$$



# Como obter a posteriori

A essência da abordagem bayesiana é tratar o parâmetro desconhecido  $\theta$  como uma variável aleatória, especificar uma distribuição a priori para  $\theta$  que represente as convicções sobre  $\theta$  antes de ver os dados, usar o Teorema de Bayes para atualizar as convicções a priori na forma de probabilidades a posteriori e fazer inferências apropriadas. Portanto há quatro passos característicos da abordagem bayesiana:

- ① especificação da verossimilhança do modelo  $L(\theta | y) \equiv f(y | \theta)$ ;
- ② determinação da priori  $f(\theta)$ ;
- ③ cálculo da distribuição posteriori  $f(\theta | y)$ , obtida pelo Teorema de Bayes;
- ④ extrair inferências da distribuição posteriori.

# Como obter a posteriori

O Teorema da Bayes expresso em termos de variáveis aleatórias, com densidades denotadas genericamente por  $f(\cdot)$ , tem a forma:

$$f(\theta | y) = \frac{f(\theta)f(y | \theta)}{f(y)} = \frac{f(\theta)f(y | \theta)}{\int f(\theta)f(y | \theta)d\theta} \quad (3)$$

No caso contínuo  $f$  é a função de densidade de probabilidade como usual, mas no caso discreto,  $f$  é a função de massa de probabilidade de  $Y$  [ $P(Y = y)$ ]. De forma similar,  $\theta$  pode ser discreto ou contínuo mas, caso seja discreto,  $\int f(\theta)f(y | \theta)d\theta$  deve ser interpretado como  $\sum_j f(\theta_j) f(y | \theta_j)$ .

Pode-se então dizer que:

$$posteriori = \frac{priori \times verossimilhana}{marginal} \quad (4)$$

# Como obter a posteriori

Note que o denominador no Teorema de Bayes é uma função apenas de  $y$ , resultante de uma integração em  $\theta$  (ou seja,  $\theta$  foi "integrado fora"). Desta forma, uma outra maneira de escrever o Teorema de Bayes é:

$$f(\theta \mid y) \propto f(\theta)f(y \mid \theta) \quad (5)$$

ou, em palavras, "a posteriori é proporcional à priori vezes a verossimilhança".

# Como obter a posteriori

**Voltando ao nosso exemplo:** (Média normal.) Sejam  $Y_1, \dots, Y_n$  variáveis aleatórias independentes com uma distribuição  $N(\theta, \sigma^2)$ , em que  $\sigma^2$  é conhecido.

Então,

$$f(y_i | \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y_i - \theta)^2}{2\sigma^2} \right\} \quad (6)$$

e a verossimilhança fica

$$\begin{aligned} L(\theta | y) &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_{i=1}^n (y_i - \theta)^2}{2\sigma^2} \right\} \\ &\propto \exp \left\{ -\frac{\sum_{i=1}^n (y_i - \theta)^2}{2\sigma^2} \right\} \end{aligned} \quad (7)$$

# Como obter a posteriori

Após algum algebrismo é possível mostrar que esta expressão pode ser escrita na forma

$$L(\theta | y) \propto \exp \left\{ -\frac{(\theta - \bar{y})^2}{2(\sigma^2/n)} \right\} \quad (8)$$

Agora, suponha que as convicções a priori sobre  $\theta$  podem elas mesmas serem representadas por uma distribuição normal  $\theta \sim N(b, d^2)$ .

# Como obter a posteriori

Novamente, esta escolha visa obter uma análise matemática simples, mas deve apenas ser usada se tal escolha é de fato uma boa aproximação à crença a priori sobre  $\theta$ . Então, pelo Teorema de Bayes,

$$\begin{aligned} f(\theta | y) &\propto \exp \left\{ -\frac{(\theta - b)^2}{2d^2} \right\} \exp \left\{ -\frac{(\theta - \bar{y})^2}{2(\sigma^2/n)} \right\} \\ &= \exp \left\{ -\frac{1}{2} \left[ \frac{(\theta - b)^2}{d^2} + \frac{(\theta - \bar{y})^2}{\sigma^2/n} \right] \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left[ \left( \frac{1}{d^2} + \frac{1}{\sigma^2/n} \right) \theta^2 - 2\theta \left( \frac{b}{d^2} + \frac{\bar{y}}{\sigma^2/n} \right) \right] \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left( \frac{1}{d^2} + \frac{1}{\sigma^2/n} \right) \left[ \left( \theta - \frac{\frac{b}{d^2} + \frac{\bar{y}}{\sigma^2/n}}{\frac{1}{d^2} + \frac{1}{\sigma^2/n}} \right)^2 \right] \right\} \end{aligned}$$

# Como obter a posteriori

Portanto,

$$\theta \mid y \sim N \left( \frac{\frac{b}{d^2} + \frac{n\bar{y}}{\sigma^2}}{\frac{1}{d^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{d^2} + \frac{n}{\sigma^2}} \right) \quad (9)$$

que é igual a equação 2 do nosso exemplo.

## Continuação do exemplo

Agora, como a distribuição Normal é unimodal e simétrica, a região HPD de  $100(1 - \alpha)\%$  para  $\theta$  é:

$$\left( \frac{\frac{b}{d^2} + \frac{n\bar{y}}{\sigma^2}}{\frac{1}{d^2} + \frac{n}{\sigma^2}} \right) \pm z_{\alpha/2} \left( \frac{1}{\frac{1}{d^2} + \frac{n}{\sigma^2}} \right)^{\frac{1}{2}}$$

em que  $z_{\alpha/2}$  é o ponto com porcentagem desejada da distribuição normal padrão  $N(0, 1)$ . Note, além do mais que à medida que  $d \rightarrow \infty$  o intervalo se torna:

$$\bar{y} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

que é precisamente o intervalo de confiança para  $100(1 - \alpha)\%$  de  $\theta$  obtido em inferência clássica. Neste caso especial, o intervalo de credibilidade e o intervalo de confiança são idênticos, embora as suas interpretações sejam bastante diferentes.



## ESTIMATIVA DE ESTADO E DE PARÂMETROS EM MODELAGEM DO TRATAMENTO DE TUMOR PROSTÁTICO VIA RADIOTERAPIA E HORMONIOTERAPIA

Prof. Dr. José Mir Justino da Costa  
Prof. Dr. Jeremias da Silva Leão

- Neste trabalho, foi apresentada uma adaptação de um modelo matemático existente na literatura para tratar o câncer de próstata utilizando radioterapia e hormonioterapia em conjunto.
- O modelo adaptado é composto por um sistema de equações diferenciais acopladas.
- Como o trabalho está relacionado a Problemas Inversos, foi utilizada uma análise inversa com um filtro Bayesiano.
- Estima as variáveis de estado e parâmetros do modelo.
- A qualidade do ajuste foi avaliada usando o erro quadrático médio (EQM).

Apresentar um modelo matemático da literatura, baseado em Equações Diferenciais Ordinárias (EDO) e modificá-lo para incorporar tratamento de câncer de próstata via radioterapia e hormonioterapia, bem como usar filtro Bayesiano para estimativa combinada de estados e parâmetros.

Para a geração das medidas que foram utilizadas neste trabalho adotamos o seguinte:

$$\eta_{medido} = \eta_{simulado} + \varepsilon$$

Em que,  $\eta_{medido}$ , resulta da soma de  $\eta_{simulado}$ , que é a solução do problema direto e de  $\varepsilon$ . Aqui consideramos  $\varepsilon$  como uma variável aleatória tendo distribuição normal, com média igual a zero e variância conhecida e igual a 5% do valor máximo de cada população medida. Vale ressaltar que foi gerado medidas apenas para a população de células normais e tumorais.

- Os problemas inversos formam um conjunto de problemas matemáticos onde se objetiva determinar a causa de um fenômeno particular (solução do problema), observando-se o efeito por ele produzido (dados).
- Neste trabalho foi utilizado o filtro de partículas proposto por (LIU; WEST, 2001) para estimar simultaneamente os estados do processo (população celular) e os parâmetros do modelo matemático modificado.

Em um problema de estimativa de estado consideramos o seguinte modelo de evolução:

$$x_k = f(x_{k-1}, v_{k-1}) \quad (10)$$

onde,

- $x$  é o vetor de estado que contém todas as variáveis que serão estimadas dinamicamente
- o subscrito  $k = 1, 2, \dots$ , representa o instante de tempo  $t$
- $f$  é geralmente uma função não linear das variáveis de estado  $x$  e do vetor de incertezas  $v$

Sendo  $z_k \in \mathbf{R}^n$  as medidas observadas e  $\eta \in \mathbf{R}^n$  as incertezas associadas a essas medidas, podemos considerar o modelo de observação ou de medidas como:

$$z_k = h(x_k, \eta_k) \quad (11)$$

O problema de estimação de estado tem por objetivo obter informações sobre  $x_k$  baseado nas equações (10 - 11), e as seguintes suposições são feitas:

(i) A sequência  $x_k$  para  $k = 1, 2, \dots$  é um processo Markoviano de primeira ordem, ou seja

$$\pi(x_k \mid x_0, x_1, \dots, x_{k-1}) = \pi(x_k \mid x_{k-1})$$

(ii) A sequência  $z_k$  para  $k = 1, 2, \dots$  é um processo Markoviano com respeito a história de  $x_k$ , isto é:

$$\pi(z_k \mid z_0, z_1, \dots, z_{k-1}) = \pi(z_k \mid z_{k-1})$$

(iii) A sequência  $x_k$  depende das observações passadas através da sua própria história, ou seja:

$$\pi(x_k \mid x_{k-1}, z_{1:k-1}) = \pi(x_k \mid x_{k-1})$$

onde a expressão  $\pi(a \mid b)$  representa a densidade de probabilidade de  $a$  dado  $b$ .



Outras suposições também são feitas, tais como (KAIPPIO; SOMER-SALO, 2006):

(a) Os vetores de ruídos  $\mathbf{v}_i$  e  $\mathbf{v}_j$  para  $i \neq j$ , bem como  $\eta_i$  e  $\eta_j$  são mutuamente independentes e mutuamente independentes do estado inicial  $\mathbf{x}_0$ .

(b) Os vetores  $\mathbf{v}_i$  e  $\eta_i$  são mutuamente independente para todos os valores de  $i \neq j$ .

Sendo  $\pi(\mathbf{x}_0 | \mathbf{z}_0) = \pi(\mathbf{x}_0)$  uma informação a priori no instante inicial  $t_0$  em um problema de filtragem o objetivo é obter uma aproximação da distribuição a posteriori  $\pi(\mathbf{x}_k | \mathbf{z}_{1:k})$ . Esta posteriori é obtida em dois passos: previsão e atualização.

Como neste trabalho estamos interessados na estimativa combinada de estados e parâmetros, usou-se o filtro de (LIU; WEST, 2001) que é uma generalização do filtro ASIR. Neste filtro a inferência é feita sobre

a densidade a posteriori conjunta  $\pi(x_k, \theta | z_{1:k})$ . Sendo  $\theta$  o vetor de parâmetros e  $x_k$  as variáveis de estado. (LIU; WEST, 2001) assume que para um vetor de parâmetros estáticos  $\theta$  a aproximação da densidade a posteriori  $\pi(\theta | z_k)$  é feita por densidade suavizada via kernel

$$\pi(\theta | z_k) \approx \sum_{i=1}^N w_k^i N(\theta | m_k^i, h^2 V_k) \quad (12)$$

Dessa forma temos que a distribuição artificial do parâmetros  $\theta$  é representada pela mistura ponderada por  $w_k^i$  de distribuições normais com média  $m_k^i$  e variância  $h^2 \mathbf{V}_k$  ((LIU; WEST, 2001),(COSTA, 2015)).

A sugestão ainda de (LIU; WEST, 2001) é a de que a constante  $h$ , parâmetro de suavização, seja escolhida como uma função suave e decrescente com relação a  $N$ . Outras considerações feitas foram que:

$$\mathbf{m}_k^i = a\boldsymbol{\theta}_k^i + (1 - a)\bar{\boldsymbol{\theta}}_k. \quad (13)$$

$$a = \sqrt{(1 - h^2)}. \quad (14)$$

$$\bar{\boldsymbol{\theta}} = \frac{1}{N} \sum_{i=1}^N \boldsymbol{\theta}_k^i. \quad (15)$$

$$\mathbf{V}_k = \frac{1}{N} \sum_{i=1}^N (\boldsymbol{\theta}_k^i - \bar{\boldsymbol{\theta}}) (\boldsymbol{\theta}_k^i - \bar{\boldsymbol{\theta}})^T, \quad (16)$$

onde  $T$  denota o transposto da matriz,  $a$  está relacionado a um fator de desconto  $\delta$  de acordo com (LIU; WEST, 2001) da seguinte forma :

$$a = \frac{3\delta - 1}{2\delta} \quad (17)$$

# Resultados

A utilização do filtro de partículas para estimativa combinada de variáveis de estado e parâmetros funcionou de forma bastante satisfatória. Até mesmo para a variável, população de células imunológicas a qual não tínhamos medida, o filtro conseguiu boa estimativa quando utilizadas 5000 partículas. Com relação aos parâmetros também foram obtidos, em geral, um bom ajuste quando comparados aos valores exatos. Dada a natureza não linear do modelo utilizado alguns parâmetros precisaram de quantidade de partículas maiores do que para outros parâmetros.